

INTRODUCTION : LE SCORE QUI PARLE AVANT VOUS

Imaginez un instant :

-

vous entrez dans une salle d'audience.
Devant le juge, votre dossier est posé.

-

Vous respirez, vous attendez.

-

Mais avant même qu'un mot soit prononcé, un chiffre apparaît en haut de la page :

« **Risque de récidive : 87 %** »

-

Ce chiffre ne vient pas d'un humain.
Il vient d'un algorithme entraîné sur 1,4 million de dossiers judiciaires du Wisconsin.

Un modèle qui ne connaît rien de votre histoire personnelle,
mais qui connaît très bien les statistiques des personnes qui vous ressemblent sur le papier :
votre âge, votre quartier, vos antécédents — même minimes.

Dans de nombreux tribunaux américains, ce score influence déjà les décisions.
Pour le juge, c'est un outil d'aide.
Pour vous, c'est une étiquette.

Le problème, c'est que ce score ne reflète pas seulement votre comportement.
Il reflète tout le système qui vous précède : les habitudes policières, les types d'infractions
surveillées, les populations les plus souvent contrôlées — bref, les biais déjà présents dans les
données.

Transition vers la présentation des données

Après avoir imaginé cette scène, il devient évident que ce “score de récidive” ne se résume pas
à un simple chiffre. Il est construit à partir de données historiques et de décisions passées. Pour
comprendre ce qu'il reflète réellement et détecter les biais qu'il peut contenir, il est essentiel de
se pencher d'abord sur la **nature des données** utilisées : le Wisconsin Circuit Courts

Longitudinal Dataset (WCLD), ses variables clés et les informations qu'il fournit sur les défendeurs et leur environnement.

Cependant, l'utilisation de ces outils soulève une interrogation centrale : dans quelle mesure ces modèles prédictifs sont-ils réellement neutres ? Étant entraînés sur des données judiciaires historiques qui portent la trace de pratiques policières, de décisions judiciaires et d'inégalités sociales parfois profondément ancrées, ils risquent de reproduire, voire d'amplifier les biais qu'ils héritent du système dont ils proviennent.

Cette réflexion conduit à la problématique de notre étude :

Dans quelle mesure les modèles prédictifs de récidive reflètent-ils les biais sociaux et raciaux présents dans les données judiciaires, et comment distinguer ce qui relève de la réalité criminelle de ce qui relève des inégalités structurelles ?

Trois questions en découlent :

1. **Quels biais sont déjà présents dans les données et comment influencent-ils les analyses ?**
2. **Les modèles prédictifs peuvent-ils être considérés comme neutres, ou reproduisent-ils les inégalités existantes ?**
3. **Quelle est l'influence réelle des variables socio-économiques et démographiques sur les prédictions ?**

Pour répondre à ces questions, nous nous appuyons sur la base de donnée WCLD

Presentation de la base

Cette base, appelée WCLD, rassemble environ 1,5 million d'affaires criminelles jugées entre 1970 et 2020. Imaginez un instant : 1,5 million de vies, de décisions, de parcours judiciaires, toutes documentées et codées dans un dataset. Pour chaque dossier, nous avons des informations sur le type de délit, le juge qui a tranché, la durée de la peine et le statut de probation.

Mais ce n'est pas tout. Nous connaissons également le profil des défendeurs : leur âge, leur sexe, leur origine, et leur historique judiciaire — certains avaient déjà plusieurs délits, d'autres en étaient à leur première affaire.

Et le contexte social est documenté lui aussi : le quartier de résidence, le revenu moyen des habitants, la proportion d'Afro-Américains ou d'Hispaniques, le taux de diplômés, ainsi que le statut rural ou urbain. Toutes ces informations nous permettent de comprendre non seulement **le parcours individuel**, mais aussi **l'influence de l'environnement** sur les décisions judiciaires.

Enfin, la variable clé que nous analysons est **is_recid_new**. Elle nous indique si un défendeur a commis un nouveau délit du même type dans les deux ans suivant son jugement. Grâce à cette variable, nous pouvons relier le profil de la personne, son environnement et son dossier judiciaire à la question centrale de notre étude : **le risque de récidive et ce qu'il reflète réellement**.

Nettoyage des données

"Mesdames et Messieurs, imaginez la scène. Vous êtes dans une salle d'audience. Devant vous, un dossier. Mais ce dossier... il est incomplet. Des informations manquent. La moitié des peines de prison ne sont pas renseignées. Un tiers des informations sur la probation sont absentes. Et pour presque 3 % des accusés, on ignore même leur code postal.

Que ferait le juge dans ce cas ? Il pourrait se tromper. Et un algorithme, lui, n'hésite pas : il lit ce qu'il a et tire des conclusions... parfois fausses.

C'est pourquoi nous avons commencé par nettoyer ces données. Nous ne pouvions pas laisser ces erreurs guider nos décisions.

Première étape : corriger les évidences. L'âge d'un accusé au moment de l'infraction ne peut pas dépasser son âge au moment de l'infraction. Nous avons vérifié ces incohérences et ajusté chaque anomalie.

Deuxième étape : les gros poissons. Les peines manquantes — nous avons utilisé une approche logique :

- si un accusé avait des pairs avec le même nombre d'antécédents et le même type de délit, nous avons pris la peine moyenne de ce groupe,
- sinon, nous avons regardé ses propres affaires passées,
- et si aucune information n'était disponible, nous avons pris la moyenne générale.

Le cas de la probation et de la cohérence juridique était plus complexe.

Nous avons trois variables principales : **jail**, qui indique la durée de détention ;

release, qui vaut 0 si la personne est en prison et 1 si elle est libérée ou en probation ;

et **probation**, qui vaut 1 si la personne est en probation et 0 sinon.

Si sur une ligne **release=1** et **jail>0**, cela constituait une incohérence. Nous avons décidé que si **probation** était égal à 1 ou vide, cela signifiait que la personne était en probation, et nous avons transformé la colonne **release** en une colonne indiquant uniquement les personnes réellement libérées.

Si **probation** était égal à 0, alors l'erreur venait de **jail** : la personne était libre et ne pouvait pas être en prison en même temps, donc nous avons mis **jail** à zéro. Toutes les autres combinaisons impossibles ont été corrigées pour assurer la cohérence interne.


Résultat : chaque dossier est maintenant cohérent. Chaque accusation, chaque peine, chaque statut est clair. Ce dataset, auparavant fragile, est prêt. Prêt à être analysé. Prêt à révéler ce que les chiffres disent réellement sur le risque de récidive.

Mesdames et Messieurs, considérez ceci comme la première étape de justice dans notre enquête sur l'algorithme. Sans ce nettoyage, tout jugement basé sur ces données serait... dangereux.

Cette phase de nettoyage a été un véritable procès en soi. Elle nous a demandé près de **18 heures de travail minutieux**, à examiner chaque dossier, chaque incohérence, chaque donnée manquante.

→ Transition : **Maintenant, comme en salle d'audience, examinons les données : chaque chiffre, chaque variable, nous révèle comment le risque de récidive est évalué.**

EDA



Pour commencer notre exploration, nous avons commencé par examiner la distribution de la variable cible. Le constat est clair : notre base contient environ **55 000 non-récidivistes** et **40 000 récidivistes**, ce qui traduit un déséquilibre modéré qu'il faudra garder en tête pour la suite de l'analyse.

Ensuite, nous avons regardé la distribution des infractions et des antécédents dans la base. La majorité des dossiers du Wisconsin concernent des délits mineurs, classés entre 7 et 10 sur une échelle de gravité de 1 à 20. Les crimes graves, comme les meurtres ou incendies criminels, sont très rares. Autrement dit, l'algorithme, lorsqu'il sera construit, apprendra surtout à prédire le comportement pour des délits du quotidien.

Côté antécédents, trois catégories se distinguent : les crimes graves (environ 970 000 personnes), les délits mineurs (1,4 million) et les autres infractions (700 000). Les délits mineurs dominent largement, et plus une personne a

d'antécédents, plus le risque de récidive sera élevé. Mais attention : le passé interagit aussi avec l'âge, la race et le quartier pour façonner ce risque.

Enfin, la question du sexe : les hommes représentent 79,5 % des dossiers, les femmes 20,5 %. Les données historiques montrent que les hommes récidivent plus souvent que les femmes. L'algorithme tiendra compte de cette tendance et ajustera le risque en conséquence, sans juger le comportement individuel. Par exemple, deux personnes avec le même passé et le même âge, l'homme aura un risque un peu plus élevé, sans que cela juge leur comportement individuel.

Facteurs influençant la récidive : âge, quartier et densité

On a observé que les infractions se concentrent principalement chez les 20-30 ans, avec une médiane à 28 ans. Les plus jeunes, entre 18 et 25 ans, présentent les taux de récidive les plus élevés, tandis que les individus plus âgés voient ces taux diminuer progressivement.

On a également constaté que le quartier de résidence joue un rôle. Les zones plus pauvres, avec peu de diplômés et des revenus faibles, apparaissent de manière disproportionnée dans notre base. Cela reflète davantage l'intensité du contrôle policier et le manque de ressources pour se défendre que le comportement individuel. L'influence de ces facteurs socio-économiques reste faible comparée à l'âge ou au passé judiciaire.

Enfin, on a remarqué que la densité de population influence la probabilité d'apparaître dans le dataset. Les zones urbaines, avec plus de policiers et de contrôles réguliers, enregistrent davantage d'arrestations. Même pour le même délit, un individu vivant en ville a plus de chances d'être pris en compte dans les données qu'un individu en zone rurale.

“Les visages derrière les statistiques”

Avant même de parler de peines ou de récidive, il faut regarder qui se retrouve dans ces dossiers. Imaginez votre dossier ouvert devant le juge, et à côté, un chiffre pour chaque groupe de population :

- Caucasian : 66,3 %
- African American : 21,4 %
- Hispanic : 7,0 %
- American Indian / Alaskan Native : 4,4 %
- Asian or Pacific Islander : 0,9 %

À première vue, ce ne sont que des chiffres. Mais comparons-les à la population réelle du Wisconsin :

- White : 78,6 %
- Black : 6,2 %
- Hispanic : 7,0 %
- American Indian / Other : 1,2 %
- Asian : 3,0 %
- Multiracial : 3,5 %

On voit tout de suite que certains groupes sont disproportionnés. Les Afro-Américains, par exemple, ne représentent que 6,2 % de la population mais apparaissent dans 21,4 % des dossiers — soit 3,5 fois plus que ce que leur proportion devrait laisser attendre. Les Caucasiens, eux, passent de 78,6 % dans la population à 66,3 % dans les dossiers.

Ce n'est pas que la criminalité est différente. C'est le système qui décide qui sera contrôlé, arrêté et jugé. Les quartiers surveillés de près, les populations les plus ciblées par la police, et les biais historiques dans la justice influencent ces chiffres.

Si l'algorithme lit ces données, il n'apprendra pas le crime réel. Il apprendra le comportement du système judiciaire lui-même. En d'autres termes, il identifie qui le système juge "à risque", pas qui est réellement plus criminel.

Après avoir observé comment certaines populations apparaissent de manière disproportionnée dans les dossiers, il est naturel de se demander : une fois jugées, ces personnes reçoivent-elles le même traitement pour les mêmes infractions ?

Highest severity

Pour répondre à cette question, nous avons plongé dans la variable `highest_severity`, qui correspond à la gravité du crime.

Nous avons étudié comment la durée de prison — la colonne `jail` — varie selon chaque niveau de gravité, et ce, pour chaque groupe racial. Pour être précis et limiter l'effet des peines extrêmes, nous avons utilisé la médiane plutôt que la moyenne : elle nous indique le point central, là où la moitié des individus a une peine plus courte et l'autre moitié une peine plus longue.

Le graphique révèle que certaines races — notamment les American Indian or Alaskan Native et les African American — reçoivent des peines médianes beaucoup plus longues pour des crimes de gravité identique. D'autres groupes, comme les Asian, Caucasian et Hispanic, voient des peines plus basses et relativement stables.


En résumé : même lorsque le crime est exactement le même, certaines races écotent de peines plus longues. Cela met en lumière un biais structurel : la race influence la peine indépendamment de la gravité du crime. L'utilisation de la médiane nous permet de voir ce biais clairement, sans que les valeurs extrêmes ne le masquent.

Pour confirmer si ces différences sont réellement significatives, nous avons appliqué le test de Kruskal-Wallis, un test statistique non paramétrique qui compare plusieurs groupes quand les données ne suivent pas une distribution normale. Une valeur de p inférieure à 0,05 indique que les différences observées ne sont pas dues au hasard.

Ce que nous avons observé : pour presque toutes les valeurs de gravité, le test donne une valeur de p très faible. Concrètement :

- Gravité 7.0 : $H = 6125,52$, $p \approx 0$, une différence très marquée entre races.
- Gravité 9.0 : $H = 2850,05$, $p \approx 0$, différences encore très importantes.
- Gravité 19.0 : $H = 9,72$, $p = 0,045$, différences significatives mais moins prononcées.

Étudions plus en détail le taux de recidive par race et tranche d'âge



Pour visualiser les interactions entre âge et race, nous avons utilisé une heatmap. Voici ce qu'elle montre :

- Horizontalement (de gauche à droite) : l'âge
 - Les jeunes (18–25 ans) apparaissent en rouge, indiquant les taux de récidive les plus élevés.
 - Les individus plus âgés (55+) virent au jaune, signe de taux plus faibles
- Verticalement (de haut en bas) : la race
 - Chaque ligne correspond à un groupe racial
 - Certaines lignes restent plus rouges que d'autres pour les mêmes tranches d'âge, révélant un écart selon l'origine

Prenons un exemple.

Alex (Asiatique, 18–25 ans) et Jamal (African American, 18–25 ans) commettent exactement la même infraction. Pourtant, dans les données, des profils comme Alex récidivent en moyenne à 47 %, alors que des profils comme Jamal montent à 52 %.


Et si on ajoute Aiden (American Indian, 18–25 ans), le taux atteint 63,6 %, le plus élevé du dataset.

Ainsi, pour une faute identique et un âge identique, Alex est perçu comme “moins risqué”, Jamal comme plus risqué, et Aiden comme très risqué.

Un simple écart statistique suffit alors à influencer la sévérité de la peine, même si tous trois ont commis la même infraction.

En somme, ces écarts montrent que, pour une même infraction, le risque perçu dépend davantage du groupe d'appartenance que du comportement réel, ouvrant la porte à des décisions judiciaires inégalitaires.

Étudions maintenant le taux de récidive **par race et antécédents**



Cette heatmap montre l'effet combiné de la race et du passé judiciaire sur le risque de récidive : plus c'est rouge, plus le taux prédit est élevé ; plus c'est vert, plus il est bas.


Horizontalement, le risque augmente avec le nombre d'antécédents.

Verticalement, pour un même nombre d'antécédents, les taux diffèrent selon la race.

Reprenons notre exemple de trois personnes, cette fois ci ils sont sans antécédents criminels. Alex, qui est d'origine asiatique, a un taux de récidive prédit de 22%. Jamal, Afro-Américain, présente un taux plus élevé de 28,5 %, soit 21 % de plus que celui d'Alex. Aiden, Amérindien, a un taux encore plus élevé, à 38,9 %, ce qui correspond à 65 % de plus que celui d'Alex.

Ainsi, on observe un écart de 15 points entre ces individus, bien qu'ils aient tous le même historique judiciaire.

Étudions l'évolution de la récidive dans le temps



Ce graphique montre une baisse progressive de la récidive entre 2000 et 2018.

Au Wisconsin et au niveau national, plusieurs facteurs ont contribué à cette tendance notamment une meilleure utilisation d'outils d'évaluation du risque (ex. COMPAS) pour ajuster peines et suivi.

Conclusion de l'EDA

Les analyses montrent que :

- **Le passé judiciaire et l'âge dominant le risque perçu.** Les jeunes et les récidivistes sont jugés "plus à risque".
- **La race influence les peines indépendamment de la gravité du crime.** Certaines populations reçoivent systématiquement un taux de récidive plus long.
- **Les facteurs socio-économiques jouent un rôle secondaire.** La pauvreté et l'éducation ont un effet limité comparé au passé et à l'âge.
- **Les réformes et changements de contrôle pénal peuvent faire baisser la récidive.**

Modélisation

Afin de comprendre comment nos algorithmes appréhendent la prédiction de la récidive — et surtout dans quels biais ils peuvent potentiellement tomber — nous avons évalué plusieurs modèles en analysant leurs performances et leurs limites, non seulement d'un point de vue statistique mais également éthique.

Pour chaque modèle, des métriques telles que l'accuracy, le rappel (recall), la précision et le F1-score ont été calculées afin d'évaluer leurs performances.

- **Régression logistique** : baseline avec 64 % d'accuracy, limite par sa linéarité.
C'est un modèle statistique qui calcule la probabilité qu'un exemple appartienne à une classe grâce à une **fonction linéaire** sur les variables
- **CatBoost** : meilleur rappel (~80 %), mais trop de faux positifs (~118 000), difficile à justifier éthiquement.
C'est un modèle de **boosting par arbres de décision** qui construit plusieurs arbres séquentiellement. Chaque nouvel arbre corrige les erreurs des précédents
- **LightGBM** : bon compromis (AUC ~0,72, rappel ~66 %), mais trop d'erreurs de classification finale.
C'est aussi un modèle de **boosting par arbres**, mais optimisé pour être très rapide et utiliser peu de mémoire. Il construit les arbres de façon "leaf-wise" (par feuille) plutôt que "level-wise" (par niveau), ce qui peut capturer plus de détails dans les données. Il traite efficacement de grandes quantités de données.
- **HistGradientBoosting** : précision ~64 %, limite mieux les faux positifs, choix éthique prioritaire.

Modèle de **boosting par arbres** qui accélère l'apprentissage en regroupant les valeurs des variables continues en **buckets (histogrammes)**. Cela réduit la complexité du calcul et permet de construire les arbres plus rapidement. Il cherche un bon compromis entre vitesse et performance.


Atteindre plus de 70 % d'accuracy en prédiction de récidive est très difficile, car cela implique des comportements humains complexes. Notre meilleur modèle est donc le HistGradientBoosting, avec une précision de 64% et un taux de faux positif et faux négatifs relativement plus petit . Il reste donc conforme aux standards et proche des 65 % du logiciel COMPAS utilisé aux États-Unis.

Au-delà de la performance, il est crucial d'évaluer l'équité des modèles. En contexte sensible comme la récidive, la question n'est pas seulement « qui est bien prédit ? », mais surtout :

“sur qui se trompe-t-il, et pourquoi ?”

L'analyse détaillée vise à étudier le comportement du modèle selon différents sous-groupes (race, sexe, revenus, antécédents, gravité des infractions) et à réaliser une analyse contre-factuelle pour détecter l'influence explicite ou implicite de variables sensibles, notamment la race.


Étudions l'impact des erreurs que le modèle a commis sur la race



Le graphique montre la répartition raciale du dataset et les taux d'erreurs par groupe. Les Caucasiens sont majoritaires, tandis que les Asian/Pacific Islander et American Indian/Alaskan Native sont minoritaires, ce qui impacte l'apprentissage. Les American Indian/Alaskan Native présentent un taux de faux positifs très élevé (~50 %), c'est-à-dire que ce sont des individus **non récidivistes que le modèle classe à tort comme récidivistes**. À l'inverse, les Hispanics ont un taux de faux négatifs d'environ 60 %, c'est-à-dire des **récidivistes réels que le modèle prédit à tort comme non récidivistes**.


Ces écarts montrent un biais structurel : certains groupes sont surestimés, d'autres sous-estimés, ce qui remet en cause l'équité et la fiabilité du modèle.

Étudions l'impact des erreurs que le modèle a commis sur le sexe



Le graphique montre un fort déséquilibre entre les hommes et les femmes puisqu'il y a 80% d'hommes et 20% de femmes. Ce manque d'équité dans les données pourrait influencer l'apprentissage. On constate que le modèle produit presque deux fois plus de faux positifs chez les hommes — il surestime donc leur risque — tandis que les femmes présentent davantage de faux négatifs, révélant une sous-estimation de leur risque réel. Ces écarts indiquent un biais net entre les sexes.

Étudions l'impact des erreurs que le modèle a commis sur les antécédents



Le modèle s'appuie trop fortement sur **les antécédents**, ce qui crée un biais majeur : il surestime le risque de récidive pour les personnes avec de nombreux antécédents et le sous-estime pour celles qui en ont peu.

Ce déséquilibre se reflète dans les erreurs : les individus avec beaucoup d'antécédents présentent un taux très élevé de **faux positifs** (~66 %), tandis que ceux avec peu ou pas d'antécédents affichent un taux massif de **faux négatifs** (~75 %).

En bref, le modèle applique une logique trop simpliste qui part du principe que s'il y a plus d'antécédents le risque de récidive est forcément plus élevé.

En conclusion les analyses montrent que le modèle **reproduit les biais des données** :

- biais raciaux,
- biais de genre,
- surpoids des antécédents,
- sous-détection générale du risque.

En bref : le modèle est performant, mais **pas équitable**.

Passons maintenant à l'analyse contrefactuelle pour détecter l'influence explicite ou implicite de variables sensibles comme la race.

À la suite des écarts observés entre groupes raciaux, une analyse contrefactuelle a été réalisée pour mesurer l'impact réel de la variable **race** dans le modèle HistGradientBoosting.


Nous avons sélectionné un échantillon d'individus prédits *non-récidivistes* et, pour chacun, créé plusieurs versions identiques de leur profil en ne modifiant qu'un seul élément : la race (testée successivement pour les cinq catégories du dataset).

Toutes les autres caractéristiques restent inchangées, ce qui permet d'isoler l'effet propre de la race sur la probabilité de récidive et la décision finale du modèle.

Visualisons la moyenne de la probabilité de récidive lorsqu'on change uniquement la race.

Pour donner un exemple de notre base de données,

Nous pouvons voir que pour une même personne d'origine Amérindienne ou Alaskane en la faisant passer pour un caucasien, un asiatique ou un hispanique cette personne qui était sensé être noté récidiviste ne le devient plus, avec un risque qui passe de 60% à 46% voir 40% pour les personnes d'origine asiatiques.



Ainsi ,les résultats montrent clairement que :

- le modèle associe les AfroAméricains et Amérindiens ou les natifs d'Alaska à un risque de récidives plus élevé.
- **Le modèle associe les Caucasian et Asian or Pacific Islander a un risque de récidive faible.**
- **Le modele n'a presque pas d'impact sur les Hispanic**


Ces résultats contrefactuels confirment donc que la variable *race* influence directement la prédiction du modèle, même lorsque toutes les autres caractéristiques restent identiques. L'étape suivante a donc consisté à vérifier si ce biais persiste même lorsque la variable *race* est retirée, ou s'il réapparaît indirectement via d'autres variables fortement corrélées. C'est pourquoi nous avons poursuivi l'analyse en examinant l'impact de la suppression de la *race* — seule puis combinée avec ses variables proxy — afin d'évaluer jusqu'où le modèle dépend réellement de cette information sensible.

Suppression de la variable *race* et impact sur le modèle

Après retrait de la variable *race*, on a constaté que la performance du modèle diminue très légèrement.

Cela s'explique par le fait que le modèle peut reconstituer l'information raciale via d'autres variables corrélées (ex. nombre de priors, sévérité des infractions, détention, âge), un phénomène appelé **proxy discrimination**.

Ainsi, nous avons cherché à identifier les variables corrélées à race, afin de déterminer si ce ne seraient pas ces variables associées plutôt que la race elle-même qui influenceraient significativement le modèle.



Nous avons d'abord constaté grâce au graphique d'importance des variables que la race ne fait pas partie des facteurs les plus significatifs utilisés par le modèle pour prédire la récidive. Toutefois, notre analyse de corrélation a montré que la race est fortement corrélée avec med_hhinc, une variable qui, elle, figure parmi les plus importantes dans le modèle.

```
▼ *** === Corrélations numériques avec race ===  
  
race_encoded          1.000000  
proxy_socioeco        0.318888  
med_hhinc             0.303184  
pct_rural             0.231440  
pct_male              0.186202  
pct_somcollege        0.093027  
release               0.079806  
year                  0.041170  
prior_charges_severity7 0.036821  
county                0.032337  
age_offense           0.031230  
..                   - - - - -
```

Pour mieux comprendre l'impact de ces deux variables dans la prédiction de la récidive et vérifier si la race pouvait agir indirectement à travers une variable fortement corrélée, nous avons alors décidé de retirer simultanément race et med_hhinc du modèle.

=====

ÉVALUATION : HistGradientBoosting ÉTHIQUE

=====

📊 Matrice de confusion :

TN (Vrais Négatifs)	: 181,718
FP (Faux Positifs)	: 51,048
FN (Faux Négatifs)	: 82,369
TP (Vrais Positifs)	: 91,003

On constate que la suppression de la variable race et des variables fortement corrélées a entraîné une baisse mesurable de la performance globale du modèle. Toutefois, cette diminution doit être interprétée dans un cadre éthique : en retirant des variables qui captaient indirectement des disparités raciales structurelles, on réduit significativement le risque que le modèle reproduise ou amplifie des discriminations historiques.

La question centrale devient alors : faut-il privilégier un modèle plus performant au détriment de l'équité et des droits fondamentaux ?

Autrement dit, jusqu'où sommes-nous prêts à aller pour obtenir quelques points de performance supplémentaires, si cela signifie potentiellement pénaliser injustement certaines populations ?

En conservant un modèle plus « équitable », même moins performant, on s'éloigne d'un système algorithmique qui condamnerait parfois silencieusement des individus à cause de leur appartenance raciale ou de facteurs socio-économiques hérités.

Choisir un modèle plus performant mais biaisé reviendrait à sacrifier l'éthique humaine sur l'autel de l'efficacité statistique, exposant certaines personnes à des décisions défavorables uniquement parce qu'elles appartiennent à un groupe historiquement vulnérable.

Ainsi, les résultats montrent que :

- la performance brute ne peut pas être le seul critère d'évaluation d'un modèle décisionnel,
- un compromis entre précision et justice doit être assumé explicitement,
- et qu'un modèle moins performant mais plus juste respecte davantage les principes fondamentaux d'équité, de neutralité, et de dignité humaine.

En fin de compte, la vraie question n'est pas seulement « quel modèle prédit le mieux ? », mais quel modèle prédit de manière responsable et moralement acceptable.

! 🤔 - Il est essentiel de rappeler que la récidive est un phénomène complexe, influencé par des facteurs sociaux, économiques et individuels, et qu'aucun modèle ne peut la prévoir parfaitement. Même après suppression de la variable race, le modèle peut reconstruire

indirectement ces informations via des variables corrélées, illustrant la difficulté de dissocier performance et équité. Cela souligne qu'un modèle moins performant mais plus juste reste préférable, car la vraie question n'est pas seulement « qui prédit le mieux », mais « qui prédit de manière responsable et moralement acceptable ».

CONCLUSION

Imaginez : un score. Un simple nombre, posé en haut d'un dossier, qui prétend résumer une vie, un parcours, un risque. Derrière ce chiffre, des millions de décisions, de contrôles, de jugements — et des biais qui se répètent.

Notre analyse l'a montré : les modèles de prédiction de récidive, aussi puissants soient-ils, ne sont pas neutres. Ils apprennent non seulement les comportements humains, mais aussi ceux du système qui les a produits. Les Afro-Américains et les Amérindiens y sont plus souvent classés "à risque", même à profil égal. Les variables socio-économiques, comme le revenu ou le quartier, prolongent ces inégalités sous une autre forme.

Retirer la race du modèle ne suffit pas : les corrélations la font revenir par d'autres chemins. Ce constat rappelle une vérité simple : la donnée n'est jamais vierge, elle porte la trace du monde qui l'a créée.

Alors, faut-il choisir la performance ou la justice ?

Nous avons fait un pas dans une direction claire : mieux vaut un modèle un peu moins précis, mais plus équitable. Car en matière de liberté, quelques points de précision ne valent jamais un biais de trop.